




01 Tổng quan kiến trúc

Hai encoder độc lập, chọn bằng chứng theo thời gian, fusion theo ranh giới và hai decoder.

AUDIO BRANCH



VIDEO BRANCH




Các đầu vào ghi tên trong khối là tensor được truyền tiếp; xem trang chi tiết để theo dõi mọi nhánh.
a và g đi thẳng vào nominal decoder; nhánh này không bị nhân với reliability weights.
Motion regressor và 7 thành phần loss được tách ở trang 7.
Các classifier gọi là 'teacher' được tái sử dụng và fine-tune cùng encoder.
Sơ đồ mô tả một forward pass 8 frame; không thêm ensemble/TTA hay số đo accuracy từ PDF mẫu.


02 Chi tiết hai encoder

Shape giữ đầy đủ batch axis; N = B*8 là batch frame của EfficientNet-B0.

AUDIO: FRONTEND + PANNS_CNN6




VIDEO: SHARED EFFICIENTNET-B0



MBConv: expansion -> depthwise conv -> squeeze-excitation -> projection; residual khi shape cho phép.
Video train augmentation dùng cùng flip/brightness cho toàn clip; eval chỉ resize + normalize.
LN = LayerNorm; DO = dropout (chỉ train). STFT/Mel weights frozen; encoder và classifier fine-tune.
Không có fusion giữa các CNN stages; fusion nhận feature sau pooling và classifier-input hooks.

03 Temporal evidence & attention


Audio toàn clip điều kiện hóa event gate và ba query; attention được chuẩn hóa theo 8 frame.



Ba boundary tương ứng các conditional tasks: r > 0; r > 1 | r >= 1; r > 2 | r >= 2.
Temporal attention có ba phân phối frame riêng; g là mean theo boundary, không phải mean thẳng f_v.
Event gate được học qua objective chung; code không có event-label loss riêng.
Motion được tính trên projected frame embeddings, không phải optical flow hoặc pixel difference.
a được broadcast trên 8 frame tại event gate; c cũng đi tới motion regressor [trang 7].


04 Teacher residual & reliability

Classifier gốc vẫn nằm trong forward pass; các đầu ra auxiliary đồng thời điều khiển confidence.



05 Fusion theo từng ranh giới

Khởi dưới được lặp độc lập cho $k = 0, 1, 2$ với projection, interaction và classifier riêng.



w chỉ nhân weighted-sum features và teacher logits; abs-difference/product không được gate trực tiếp.


I_k được lấy trước classifier và trước teacher-logit residual.

Fusion làm việc trên vector 256D; không cập nhật các spatial feature maps trong hai CNN.

CORN dùng ba conditional decisions để biểu diễn bốn mức: none < weak < medium < strong.

06 Hai decoder & dự đoán cuối

Ordinal distribution được hiệu chỉnh bằng nominal logits với một coupling gate học được.



LABEL MAPPING DÙNG XUYỀN SUỐT MÔ HÌNH

Dataset ID	Tên lớp	Ordinal rank
0	none	0
1	strong	3
2	medium	2
3	weak	1

a và g ở nominal head là projected audio và pooled temporal video, chưa qua modality weighting.
argmax(rank_probabilities) có thể khác prediction cuối do nominal correction và thứ tự label.
clipwise_output là log-probability; khi hiển thị xác suất dùng exp, không hiển thị trực tiếp số âm.

07 Huấn luyện & toàn bộ loss

Cấu hình thực tế: 120 epochs, batch 32, Adam; checkpoint chọn theo validation accuracy.

Training inputs -> augmentation/corruption -> forward [trang 1-6]

BORA action cho từng sample: 88% không thêm corruption | 10% corrupt một modality | 2% zero một modality.
Modality được chọn đều audio/video. Audio: noise SNR 5-20 dB, gain 0.5-1.0 hoặc time mask 10-20%.
Video: brightness 0.7-1.3, blur sigma 0.1-1.0 hoặc occlusion 5-20%; cùng phép biến đổi trên clip.
SpecAugment + clip flip/brightness là augmentation train riêng, vẫn có thể áp dụng ở nhóm 88%.

Supervision: dataset label y -> ordinal rank r = [0,3,2,1][y]

Boundary k = 0,1,2: target t_k = 1[r > k]; active mask M_k = 1[r >= k].
CORN(x,r) = mean của BCEWithLogits(x_k,t_k) trên tất cả phần tử active trong batch.
Loss reliability cũng dùng mask M; các loss categorical/nominal/preservation dùng dataset labels y.

WEIGHT / LOSS TERM

TENSOR VÀ CÔNG THỨC

1.00 Fused ordinal

l [B,3]

Loss definition

L_fused = CORN(l,r)

0.30 Auxiliary ordinal

u_a, u_v [B,3]

Loss definition

L_aux = CORN(u_a,r) + CORN(u_v,r)

0.10 Reliability

r_a, r_v [B,3]

Loss definition

L_rel = 0.5 * (masked SL1_a + masked SL1_v)

1.00 Final categorical

clipwise_output [B,4]

Loss definition

L_cat = NLL(clipwise_output,y)

0.10 Motion auxiliary

motion_score [B]

Loss definition

L_motion = SmoothL1(motion_score,r/3)

0.50 Nominal

n [B,4]

Loss definition

L_nom = CrossEntropy(n,y)

0.30 Teacher preservation

t_a, mean_t(t_v) [B,4]

Loss definition

L_pres = 0.5 * (CE(t_a,y) + CE(mean_t(t_v),y))

Reliability target từng modality: exp(-BCEWithLogits(u,t)).detach(); SL1 = SmoothL1(reliability,target).

Motion head: mean_t(c) -> Linear 256->256 -> GELU -> Linear 256->1 -> sigmoid.

Motion head chỉ hỗ trợ training; motion context c vẫn nằm trong đường prediction.

Total objective -> backward -> Adam step

L = L_fused + 0.3*L_aux + 0.1*L_rel + L_cat + 0.1*L_motion + 0.5*L_nom + 0.3*L_pres
Encoder branches (gồm original classifiers, BN): lr = 1e-5; fusion/head parameters: lr = 1e-4.
Fine-tune cả hai branches; STFT/Mel filter weights frozen. Early stopping patience = 20.

Nguồn đối chiếu: notebook Multimodal_Deep_Fusion_dual_decoder_effnet.ipynb, cell 0 và code module.

Cấu hình _build_config() trong notebook trùng config/train_config.json tại thời điểm dựng sơ đồ.

Core encoder/fusion/decoder/loss được kiểm tra từ code; PDF mẫu chỉ định hướng cách trình bày.

Số đo 97.82% trên tài liệu mẫu không được gán cho mô hình này.